ChronoFuse

SemEval-2027 Task 1 (RETECO), Track 1 TEMPO için
zaman ve metadata farkındalıklı hibrit erişim

Proje Durum Raporu

Ahmet Önder Önlü
İstanbul Teknik Üniversitesi
Repo: `https://github.com/Ahmet-Onder-Onlu/nlp-term-project`

7 Kasım 2026

Özet

Bu rapor dönem projesinin şu anki durumunu özetler: çözülen problemi, tasarlanan sistemi (ChronoFuse), kullanılan araç ve kütüphaneleri, hangi modellerin kullanıldığını ve şimdiye kadar alınan ölçülmüş çıktıları. Kısa durum: proje iskeleti ve tüm modüller yazıldı; ancak şu ana kadar *yalnızca BM25 kanalı* gerçek veride çalıştırıldı ve yalnızca *iota* domain'inde test edildi. Hiçbir embedding, reranker ya da LLM modeli henüz indirilmedi veya çağrılmadı.

İçindekiler

1 Problemin Tanımı **2**
1.1 Görev . . . 2
1.2 Veri . . . 2
1.3 Değerlendirme . . . 2
1.4 Takvim . . . 3

2 Çözüm: ChronoFuse **3**
2.1 Genel mimari . . . 3
2.2 Bileşenler ve durumları . . . 3
2.3 Özgün katkı fikirleri . . . 4

3 Kullanılan Araç ve Kütüphaneler **5**

4 Modeller: Neler İndirildi, Neler Kullanıldı? **5**

5 Çıktılar (Ölçülmüş Sonuçlar) **6**
5.1 Duman testi: iota domain'i, E0 (pasaj BM25 + MaxP) . . . 6
5.2 Üretilen dosyalar . . . 6

6 LaTeX Çıktısını Görme **6**

7 Sonraki Adımlar **7**

1 Problemin Tanımı

1.1 Görev

RETECO (*Reasoning-Oriented Retrieval*), SemEval-2027'nin 1 numaralı ortak görevidir (Innsbruck Üniversitesi, UBC ve Johns Hopkins Üniversitesi tarafından düzenleniyor). İki ana track ve beş alt görevden oluşur. Biz **Track 1: TEMPO (Temporal Grounded Retrieval)** üzerinde çalışıyoruz:

- **1a, Temporal Retrieval:** Karmaşık, zamana bağlı bir soru ve o domain'in doküman koleksiyonu verilir; sistem soru başına sıralı bir doküman listesi döndürür.
- **1b, Step-wise Temporal Retrieval:** Soru, akıl yürütme adımlarına bölünmüş olarak verilir; sistem her adım için ayrı bir sıralı liste döndürür.

Görevi zorlaştıran nokta şu: bir pasajın ilgili sayılması için hem *konu* olarak hem de *zaman* olarak soruyla örtüşmesi gerekir. Doğru konuda ama yanlış dönemden bahseden bir pasaj ilgili sayılmaz; görev sayfası da ilgisiz bir tarih içeren pasajın zamansal olarak örtüşmüş sayılmadığını açıkça belirtiyor.

Örnek sorgu (iota domain'i).

> "Why are transactions so slow? Right now each transaction takes about 30 minutes or longer … two weeks ago the developers asked to stop the spamming …"

Burada zaman *örtük* biçimde geçiyor ("right now", "two weeks ago"). Doğru cevap ise belirli bir dönemdeki geliştirici duyurularına ve protokol belgelerine dayanıyor.

1.2 Veri

Veri, Hugging Face'teki `DataScience-UIBK/RETECO-SemEval2027` (v1.1) veri setidir. Tüm metinler İngilizce StackExchange içeriğidir.

Domain sayısı	13
Toplam doküman (v1.1, tekrarlar ayıklanmış)	1.167.159
Sorgu (train / dev)	1.211 / 519
Adım, 1b (train / dev)	2.762 / 1.214
Gizli test seti	yaklaşık 350 sorgu

Domain'ler: bitcoin, cardano, iota, monero (blockchain); economics, law, politics, history (sosyal bilimler); quant, travel, workplace, genealogy (uygulamalı); hsm (bilim ve matematik tarihi). Her domain'in kendi doküman koleksiyonu vardır; train ve dev 70/30 oranında bölünmüştür.

Guidance dosyaları. Train ve dev sorguları için `guidance_*.jsonl` dosyaları her sorgunun zamansal etiketlerini içerir: zamansal niyet (ör. `ongoing_status`), beklenen zaman granülaritesi, zaman çapaları, olaylar ve adım adım bir arama planı. **Test setinde bu dosyalar yok.** Tasarımımızın merkezindeki fikirlerden biri, bu etiketleri LLM'e örnek (few-shot) olarak vererek aynı şemayı test sorguları için tahmin ettirmek (Bölüm 2).

1.3 Değerlendirme

- **Resmi metrik:** `pytrec_eval` ile ikili nDCG@10. Önce her domain'in ortalaması alınır, sonra 13 domain'in ortalaması (macro-average).
- Run dosyasında eksik kalan sorgu 0 puan alır. Gönderim formatı altı sütunlu TREC formatıdır.

- **Teşhis metrikleri** (sıralamaya girmez): Temporal Precision@10, Temporal Relevance@10, Temporal Coverage@10, NDCG|FC@10.
- **Resmi BM25 baseline'ı**, macro nDCG@10: 1a train / dev = 0,1075 / 0,1147; 1b train / dev = 0,1024 / 0,1177.

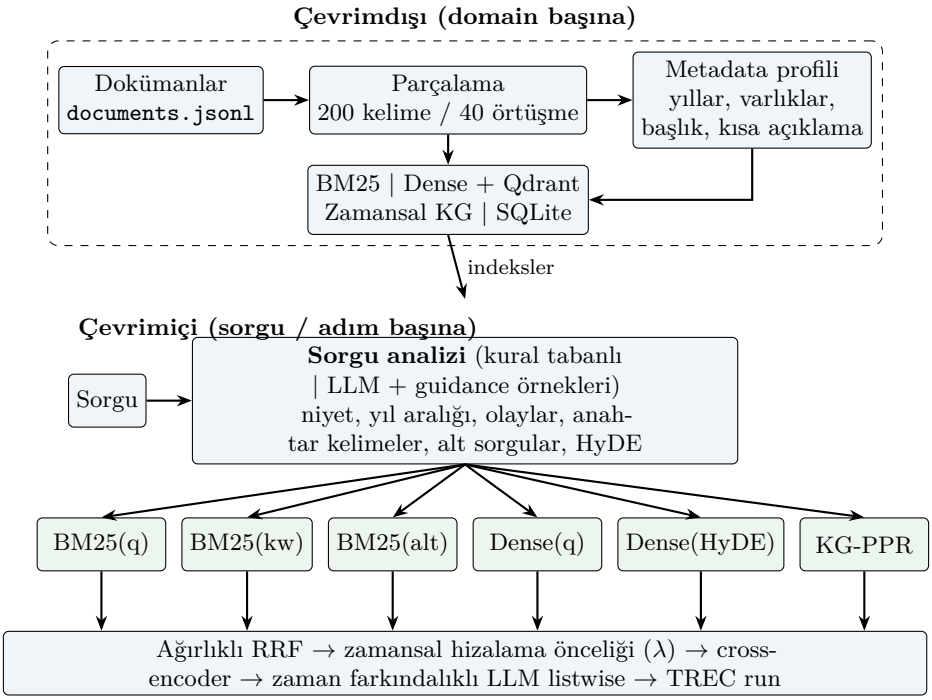
Bu düşük skorlar, salt anahtar kelime eşleşmesinin bu görevde yetersiz kaldığını ve iyileştirme için geniş bir alan olduğunu gösteriyor.

1.4 Takvim

Değerlendirme penceresi 10 Ocak 2027'de açılıp en geç 31 Ocak 2027'de kapanıyor. Makale gönderimi Şubat 2027'de (tahmini) ve ACL formatında olacak.

2 Çözüm: ChronoFuse

2.1 Genel mimari



2.2 Bileşenler ve durumları

Aşağıdaki tabloda her bileşenin kodda bulunduğu yer ve şu anki durumu var. "Çalıştırıldı", gerçek RETECO verisinde ölçüldüğü anlamına geliyor.

Bileşen	Ne yapıyor	Durum
Veri yükleyici `data/reteco.py`	Sorgu, adım, guidance, qrels ve doküman koleksiyonunu okur; sorgulardaki HTML'i temizler.	**Çalıştırıldı**
Parçalama + MaxP `metadata/chunking.py`	Dokümanları örtüşmeli pasajlara böler (en fazla 64 pasaj); doküman skoru, pasaj skorlarının en yükseğidir.	**Çalıştırıldı**
Zamansal ifade çıkarımı `metadata/temporal.py`	Yıl, yıl aralığı, ay-yıl, ISO tarih, onyıl, yüzyıl ve göreli ifadeleri ("two weeks ago") bulur ve yıllara normalize eder.	**Çalıştırıldı** (birim testli)
Doküman profili `metadata/profile.py`	Her doküman için başlık, kısa açıklama, yıllar, granülarite ve varlıkları JSONL dosyasına yazar.	**Çalıştırıldı** (iota için üretildi)
BM25 `indexing/bm25_index.py`	`bm25s` ile Lucene tipi BM25 (k_1=0,9, b=0,4), İngilizce stemmer.	**Çalıştırıldı**
SQLite doküman deposu `store.py`	Reranker'ların doküman metnine hızlı erişmesi için.	**Çalıştırıldı**
Değerlendirme `eval/metrics.py`	Resmi kurala uygun nDCG@10 (eksik sorgu 0 puan), recall@100, TREC yazma ve okuma.	**Çalıştırıldı** (resmi scorer ile birebir)
Dense erişim `indexing/dense_index.py`	sentence-transformers ile embedding, FAISS ile iç çarpım araması.	**Kodlandı, çalıştırılmadı**
Vektör veritabanı `indexing/vector_store.py`	Qdrant; payload'da yıllar tutulur, sorgunun yıl aralığına göre filtreleme yapılabilir.	**Kodlandı, çalıştırılmadı**
Zamansal bilgi grafiği `kg/temporal_kg.py`	Doküman, varlık ve yıl düğümleri; kişiselleştirilmiş PageRank ile erişim. İsteğe bağlı Neo4j'ye aktarım.	**Kodlandı, çalıştırılmadı**
Sorgu analizcisi `query/analyzer.py`	Kural tabanlı sürüm ve guidance örnekleriyle çalışan LLM sürümü (JSON çıktı).	Kural: **Çalıştırıldı** LLM: **Kodlandı, çalıştırılmadı**
Füzyon + zamansal öncelik `retrieval/`	Ağırlıklı RRF ve CombSUM; $s' = (1-\lambda)\hat{s} + \lambda\, T(q,d)$.	**Kodlandı, çalıştırılmadı** (RRF birim testli)
Cross-encoder `rerank/cross_encoder.py`	Adayları "[yıllar] başlık — pasaj" biçiminde metadata ile zenginleştirip yeniden sıralar.	**Kodlandı, çalıştırılmadı**
LLM listwise reranker `rerank/llm_listwise.py`	RankGPT tarzı kayan pencere; prompt'ta sorgunun zamansal ihtiyacı yer alır.	**Kodlandı, çalıştırılmadı**
RAPTOR tarzı küme özetleri	Domain içi hiyerarşik özetlerden ek bir erişim kanalı.	**Planlandı**

2.3 Özgün katkı fikirleri

1. **Guidance distillation:** Benchmark'ın yalnızca train ve dev için verdiği zamansal etiket şemasını LLM'e örnek olarak verip test sorguları için aynı şemayı ürettirmek. Analizcinin doğruluğu dev setinde gerçek guidance ile karşılaştırılarak ölçülebilir.
2. **Metadata'nın her aşamada kullanılması:** Aynı zamansal profil KG'de, vektör veritabanı filtresinde, zamansal öncelik skorunda ve reranker prompt'larında kullanılır.
3. **Çok kanallı hibrit erişim ve ablation:** Altı kanal tek tek açılıp kapatılarak her birinin katkısı ölçülecek.

3 Kullanılan Araç ve Kütüphaneler

Araç	Rolü	Durum
Python 3.11, conda/mamba	Çalışma ortamı (`reteco`)	**Çalıştırıldı**
PyTorch 2.15 (CPU sürümü)	Sinir ağı modelleri için altyapı (makinede GPU yok)	Kuruldu
`bm25s` + PyStemmer	Seyrek (sparse) erişim, BM25	**Çalıştırıldı**
`pytrec_eval`	Resmi nDCG@10 hesabı	**Çalıştırıldı**
SQLite, `orjson`	Doküman deposu, hızlı JSON okuma	**Çalıştırıldı**
Hugging Face Hub	Veri indirme	**Çalıştırıldı**
RETECO starter kit	Resmi `scorer.py` ve `format_checker.py` ile çapraz kontrol	**Çalıştırıldı**
sentence-transformers, FAISS	Dense erişim ve cross-encoder	**Kodlandı, çalıştırılmadı**
Qdrant (gömülü mod)	Metadata filtreli vektör veritabanı	**Kodlandı, çalıştırılmadı**
NetworkX / Neo4j	Bilgi grafiği (bellek içi / harici)	**Kodlandı, çalıştırılmadı**
OpenAI uyumlu istemci	LLM çağrıları (OpenAI, vLLM, Ollama, OpenRouter); disk önbellekli	**Kodlandı, çalıştırılmadı**
pytest, ruff	8 birim testi, lint ve biçimlendirme	**Çalıştırıldı**
Git, GitHub CLI	Sürüm kontrolü, public repo	**Çalıştırıldı**
LaTeX (ACL stili), tectonic	Makale ve bu rapor	**Çalıştırıldı**

4 Modeller: Neler İndirildi, Neler Kullanıldı?

Kısa cevap: henüz hiçbir model indirilmedi ve hiçbir LLM çağrılmadı. Şimdiye kadarki tüm sonuçlar BM25'e dayanıyor; BM25 bir istatistiksel sıralama fonksiyonu, öğrenilmiş bir model değil. Hugging Face model önbelleği kontrol edildi ve boş. Kodda tanımlı olan *varsayılan* seçimler şunlar:

Rol	Varsayılan model	Durum ve not
Embedding (dense)	`BAAI/bge-small-en-v1.5`	İndirilmedi. CPU'da hızlı olduğu için seçildi; son sistemde GPU'da daha güçlü bir model (ör. `bge-m3`) düşünülüyor.
Cross-encoder reranker	`BAAI/bge-reranker-v2-m3`	İndirilmedi.
LLM (sorgu analizi + rerank)	`.env` içindeki `LLM_MODEL` (örnek dosyadaki varsayılan: `gpt-4o-mini`)	**Henüz seçilmedi.** API anahtarı yok, hiç çağrı yapılmadı. Hangi model ve servisin (API mi, yerel Ollama mı) kullanılacağına birlikte karar verilecek.

Donanım kısıtı. Makinede GPU yok ve 7,6 GB RAM var. 1,17 milyon dokümanı CPU'da embedding'e çevirmek saatler sürer. Bu yüzden dense indeksleme için Colab/Kaggle GPU'su ya da küçük bir model gerekecek.

5 Çıktılar (Ölçülmüş Sonuçlar)

5.1 Duman testi: iota domain'i, E0 (pasaj BM25 + MaxP)

iota domain'inde 9.680 doküman ve 21.403 pasaj var. İndeks 12 saniyede kuruldu ve en fazla yaklaşık 340 MB bellek kullandı.

	Sorgu / adım	**Bizim E0**	**Resmi BM25 (iota)**	**Recall@100**
1a train	7	0,3159	0,1563	0,500
1a dev	3	0,4895	0,3309	1,000
1b train	16	0,1980	0,1403	0,719
1b dev	8	0,4539	0,4195	0,750

Resmi scorer ile çapraz kontrol (1a). Organizatörlerin `scorer.py` betiği bizim değerlendirmemizle aynı nDCG@10 değerlerini verdi; `format_checker.py` de run dosyaları için `VALID` sonucunu döndü. Resmi scorer'ın teşhis metrikleri:

	nDCG@10	TP@10	TR@10	TC@10	NDCG|FC@10
1a train	0,3159	0,1588	0,1143	0,4524	0,5585
1a dev	0,4895	0,2518	0,1667	0,5000	0,7031

Yorum ve uyarı. Bizim E0, iota'da resmi baseline'dan yüksek çıktı. Ancak bu henüz bir başarı iddiası *değil*: (i) iota'da yalnızca 7 train ve 3 dev sorgusu var, bu yüzden sonuçlar çok oynak; (ii) E0, resmi baseline'ın birebir kopyası değil (parçalama, stemmer ve tokenizer farklı). Asıl karşılaştırma 13 domain'in macro ortalamasıyla yapılacak.

5.2 Üretilen dosyalar

- `results/runs/e0_bm25/{1a,1b}_{train,dev}/iota.trec`: TREC run dosyaları
- `results/metrics/e0_bm25__*.json`: domain bazında metrikler
- `data/indexes/iota/`: BM25 indeksi, metadata profilleri, SQLite deposu
- `paper/main.pdf`: ACL formatında makale iskeleti (4 sayfa, sonuçlar boş)

6 LaTeX Çıktısını Görme

İki yol var:

1. **Overleaf:** `paper/` klasörünü zip'leyip Overleaf'te *New Project* → *Upload Project* ile yükleyin; derleyici pdfLaTeX olarak kalabilir. Klasördeki `acl.sty`, `acl_natbib.bst`, `sections/` ve iki `.bib` dosyası yeterli.
2. **Yerelde:** `reteco` ortamına `tectonic` kuruldu:

```
conda activate reteco
cd paper && tectonic main.tex                  # -> paper/main.pdf
cd reports && tectonic proje_raporu.tex        # -> bu rapor
```

7 Sonraki Adımlar

1. 13 domain'in tamamını indirmek (yaklaşık 2 GB) ve E0'ı resmi macro baseline ile karşılaştırmak. Bitcoin domain'i büyük olduğundan, 7,6 GB RAM'de indekslemeyi parça parça (batch) yapmak gerekebilir.
2. Metadata analizi: dokümanların yıl içerme oranı ve guidance'taki zamansal niyet dağılımı.
3. E1 (zamansal öncelik, λ train'de ayarlanacak) $\rightarrow$ E2 (dense + KG) $\rightarrow$ E3 (LLM analizi + reranking).
4. LLM ve embedding modeline karar vermek (API maliyeti ve GPU erişimine göre).
5. Ablation, domain ve niyet bazlı analizler; makalenin yazılması.